

Dispense di Calcolo Numerico parte 2

Ivan Gerace

A.A. 2024/2025

Indice

1	Numeri macchina	2
2	Metodi per la risoluzione di sistemi lineari	11
3	Metodi diretti	15
4	Metodi iterativi	17

Capitolo 1

Numeri macchina

Sia $x \in \mathbb{R}$, $x \neq 0$. Allora esistono e sono unici il numero intero p e la successione $\{d_i\}_{i=1,2,\dots}$ di numeri interi, con $d_1 \neq 0$ e $0 \leq d_i < \beta$, non definitivamente uguali a $\beta - 1$, tali che

$$x = \text{sign}(x)\beta^p \sum_{i=1}^{\infty} d_i \beta^{-i},$$

dove

- $\text{sign}(x) = \begin{cases} 1, & x \geq 0 \\ -1, & x < 0; \end{cases}$
- β è la base di rappresentazione;
- p è l'esponente;
- d_i sono le cifre della rappresentazione;
- $\sum_{i=1}^{\infty} d_i \beta^{-i}$ è la mantissa.

Tale rappresentazione in base β si dice **finita** se esiste un indice k tale che $d_k \neq 0$ e $d_i = 0$ per $i > k$.

La finitezza o meno dipende dalla base.

Siano $t, m, M \in \mathbb{N}^+$. Si definisce **insieme dei numeri macchina in base β con t cifre significative** l'insieme

$$\mathcal{F}_{(\beta,t,m,M)} = \{0\} \cup \left\{ x \in \mathbb{R} : x = \text{sign}(x)\beta^p \sum_{i=1}^t d_i \beta^{-i}, \text{ con } 0 \leq d_i < \beta, \right.$$

$$\left. \text{per } i = 1, 2, \dots, t, \ d_1 \neq 0, \ -m \leq p \leq M \right\}.$$

Tale insieme ha cardinalità

$$|\mathcal{F}_{(\beta,t,m,M)}| = 1 + 2(\beta - 1)\beta^{t-1}(M + m + 1).$$

Il minimo numero positivo dell'insieme, indicato con ω , è

$$\omega = (.1)_\beta \beta^{-m} = \beta^{-1} \beta^{-m} = \beta^{-m-1}$$

e il massimo numero rappresentabile, indicato con Ω , è

$$\Omega = (.(\beta - 1) \dots (\beta - 1))_\beta \beta^M = \left(\sum_{i=1}^t (\beta - 1) \beta^{-i} \right) \beta^M = (1 - \beta^{-t}) \beta^M$$

Esempio 1. Sia $\mathcal{F}_{(6,2,3,3)}$. Qual è il massimo numero ed il minimo numero pari positivo di tale insieme? Quanti numeri pari positivi contiene tale insieme?

Il massimo numero pari positivo di $\mathcal{F}(6, 2, 3, 3)$ è

$$(.55)_6 6^3 = (550.)_6 6^0 = 5 \cdot 6^2 + 5 \cdot 6 = 180 + 30 = 210.$$

Il minimo numero pari positivo è

$$(.20)_6 6^1 = (2.)_6 6^0 = 1 \cdot 6^0 = 2.$$

Se $p = 3$ abbiamo che

$$(.d_1 d_2)_6 6^3 = (d_1 d_2 0.)_6 6^0$$

sono tutti numeri pari positivi.

Per d_1 abbiamo 5 scelte (1, 2, 3, 4, 5), mentre per d_2 abbiamo 6 scelte (0, 1, 2, 3, 4, 5). Così la cardinalità di tali insiemi di numeri sono

$$5 \cdot 6 = 30.$$

Se $p=2$ abbiamo

$$(.d_1 d_2)_6 6^2 = (d_1 d_2 .)_6 6^0$$

sono numeri pari positivi solo se d_2 è pari.

Per d_1 abbiamo 5 scelte (1, 2, 3, 4, 5), mentre per d_2 abbiamo 3 scelte (0, 2, 4). Così la cardinalità di tali insiemi di numeri sono

$$5 \cdot 3 = 15.$$

Se $p=1$ abbiamo

$$(.d_1 d_2)_6 6^1 = (d_1 . d_2)_6 6^0$$

sono numeri pari se $d_2 = 0$ e $d_1 \neq 0$ è pari.

Per d_1 abbiamo 2 scelte (2, 4).

Per $p < 1$ il numero non è intero.

In totale i numeri pari positivi sono

$$30 + 15 + 2 = 47.$$

Dobbiamo rappresentare ogni numero reale con un numero macchina. Cioè che si vuole fare è trovare una funzione tale che

$$\begin{aligned} f : \mathbb{R} &\rightarrow \mathcal{F}_{(\beta, t, m, M)} \\ x &\mapsto \tilde{x} \end{aligned}$$

Sia $x = \pm \beta^p \sum_{i=1}^{\infty} d_i \beta^{-i}$, e per semplicità si assuma $\text{sign}(x) = 1$, allora si possono presentare i seguenti casi:

1. $p \notin [-m, M]$, e questo contiene in sé due sottocasi
 - (a) $p \in (M, +\infty)$ situazione di **overflow**;
 - (b) $p \in (-\infty, m)$ situazione di **underfloor**.
2. $p \in [-m, M]$, in questo caso è possibile usare due diverse funzioni

troncamento: $\tilde{x} = \text{trn}(x) = \beta^p \sum_{i=1}^t d_i \beta^{-i}$;

arrotondamento: $\tilde{x} = \text{arr}(x) = \begin{cases} \text{trn}(x), & d_{t+1} < \frac{\beta}{2}, \\ \text{trn}(x) + \beta^{p-t}, & d_{t+1} \geq \frac{\beta}{2}. \end{cases}$

Per valutare l'errore commesso nel rappresentare un numero reale $x \neq 0$ con la sua rappresentazione in numero macchina $\tilde{x}$ si considerano le seguenti quantità

$\tilde{x} - x$ detto errore assoluto;

$\varepsilon_x = \frac{\tilde{x} - x}{x}$ detto errore relativo.

Se non si verificano situazioni di underfloor o di overflow si hanno le seguenti maggiorazioni dell'errore assoluto

$$|\text{trn}(x) - x| < \beta^{p-t},$$

$$|\text{arr}(x) - x| \leq \frac{1}{2} \beta^{p-t};$$

e le seguenti maggiorazioni dell'errore relativo

$$\left| \frac{\text{trn}(x) - x}{x} \right| < \frac{\beta^{p-t}}{\beta^p d_1 \beta^{-1}} \leq \frac{\beta^{p-t}}{\beta^{p-1}} = \beta^{1-t};$$

$$\left| \frac{\text{arr}(x) - x}{x} \right| < \frac{(1/2) \beta^{p-t}}{\beta^{p-1}} = \frac{1}{2} \beta^{1-t}.$$

In generale, detta **precisione di macchina** la quantità

$$u = \begin{cases} \beta^{1-t}, & \text{se } \tilde{x} = \text{trn}(x) \\ \frac{1}{2} \beta^{1-t}, & \text{se } \tilde{x} = \text{arr}(x) \end{cases}$$

si ha che

$$|\varepsilon_x| = \left| \frac{\tilde{x} - x}{x} \right| < u.$$

Siano $x, y \in \mathcal{F}_{(\beta, t, m, M)}$, questo è sufficiente a dire che $x + y \in \mathcal{F}_{(\beta, t, m, M)}$?
In generale no, si rende quindi necessario definire un'operazione $\oplus$ tale che

$$x \oplus y \in \mathcal{F}_{(\beta, t, m, M)}.$$

In maniera analoga si devono definire $\ominus, \otimes, \oslash$.

Sia dunque $\overline{\text{op}} \in \{\oplus, \ominus, \otimes, \oslash\}$, dove $\text{op} \in \{+, -, *, /\}$, allora

$$x \overline{\text{op}} y = \begin{cases} \text{arr}(x \text{ op } y), & \text{se si lavora con arrondondamento} \\ \text{trn}(x \text{ op } y), & \text{se si lavora con troncamento} \end{cases}$$

Proprietà 1. Per le operazioni di macchina valgono

$$1. x \oplus y = y \oplus x$$

$$2. x \otimes y = y \otimes x$$

Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una funzione razionale, cioè una funzione il cui valore è ottenuto tramite un numero *finito* di operazioni aritmetiche sui dati.

$$\text{Siano } x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n \text{ i dati e } \tilde{x} = \begin{pmatrix} \tilde{x}_1 \\ \vdots \\ \tilde{x}_n \end{pmatrix} \in (\mathcal{F}_{(\beta, t, m, M)})^n \text{ i dati}$$

approssimati.

La funzione effettivamente calcolata è $\varphi : (\mathcal{F}_{(\beta, t, m, M)})^n \rightarrow \mathcal{F}_{(\beta, t, m, M)}$. Gli errori commessi possono essere di diversi tipi:

- **errore totale:** $\varepsilon_{tot} = \frac{\varphi(\tilde{x}) - f(x)}{f(x)}$;

- **errore inerente:** $\varepsilon_{in} = \frac{f(\tilde{x}) - f(x)}{f(x)}$,

è un errore generato dalla rappresentazione dei dati $x_1, \dots, x_n$ come numeri di macchina;

- **errore algoritmico:** $\varepsilon_{alg} = \frac{\varphi(\tilde{x}) - f(\tilde{x})}{f(\tilde{x})}$,

è un errore generato dal fatto che le operazioni sono effettuate in aritmetica finita in un certo ordine.

Teorema 1. Da un'analisi dell'errore totale al primo ordine si ricava

$$\varepsilon_{tot} \doteq \varepsilon_{alg} + \varepsilon_{in}.$$

Abbiamo che

$$\varepsilon_{tot} = \frac{\varphi(\tilde{x}) - f(x)}{f(x)} = \frac{\varphi(\tilde{x})}{f(x)} - 1 = \frac{\varphi(\tilde{x})}{f(\tilde{x})} \frac{f(\tilde{x})}{f(x)} - 1 =$$

$$\begin{aligned}
&= \left(\frac{\varphi(\tilde{x})}{f(\tilde{x})} - 1 + 1 \right) \left(\frac{f(\tilde{x})}{f(x)} - 1 + 1 \right) - 1 = \\
&= \left(\frac{\varphi(\tilde{x}) - f(\tilde{x})}{f(\tilde{x})} + 1 \right) \left(\frac{f(\tilde{x}) - f(x)}{f(x)} + 1 \right) - 1 = \\
&= (\varepsilon_{alg} + 1)(\varepsilon_{in} + 1) - 1 = \varepsilon_{alg} + \varepsilon_{in} + \varepsilon_{alg}\varepsilon_{in}.
\end{aligned}$$

□

Sia $f(x)$ una funzione differenziabile due volte, allora

$$f(\tilde{x}) - f(x) \doteq \sum_{i=1}^n (\tilde{x}_i - x_i) \frac{\partial f(x)}{\partial x_i}$$

è l'approssimazione data dal primo termine dello sviluppo di Taylor.

Poiché

$$\varepsilon_{in} = \frac{f(\tilde{x}) - f(x)}{f(x)} \doteq \sum_{i=1}^n \frac{(\tilde{x}_i - x_i)}{f(x)} \frac{\partial f(x)}{\partial x_i} = \sum_{i=1}^n \frac{(\tilde{x}_i - x_i)}{x_i} \left(\frac{x_i}{f(x)} \frac{\partial f(x)}{\partial x_i} \right)$$

detti

$$\begin{aligned}
\varepsilon_i &= \frac{\tilde{x}_i - x_i}{x_i} && \text{errore relativo sul dato } i\text{-esimo } x_i \\
c_i &= \frac{x_i}{f(x)} \frac{\partial f(x)}{\partial x_i} && \text{coefficiente di amplificazione su } x_i
\end{aligned}$$

risulta

$$\varepsilon_{in} \doteq \sum_{i=1}^n \varepsilon_i c_i.$$

Esempio 2 (Somma/Differenza). $f(x_1, x_2) = x_1 \pm x_2$

$\varepsilon_{in} = c_1 \varepsilon_1 + c_2 \varepsilon_2$, dove

$$c_1 = \frac{x_1}{x_1 \pm x_2} \quad c_2 = \pm \frac{x_2}{x_1 \pm x_2}$$

c_1 e c_2 sono grandi se $x_1 \cong \mp x_2$.

Esempio 3 (Moltiplicazione). $f(x_1, x_2) = x_1 x_2$, allora

$$c_1 = \frac{x_1}{x_1 x_2} x_2 = 1 \quad c_2 = \frac{x_2}{x_1 x_2} x_1 = 1$$

In questo caso non ci sono problemi di amplificazione.

Esempio 4 (Divisione). $f(x_1, x_2) = \frac{x_1}{x_2}$, allora

$$c_1 = \frac{x_1}{\frac{x_1}{x_2}} \frac{1}{x_2} = 1 \quad c_2 = \frac{x_2}{\frac{x_1}{x_2}} \left(-\frac{x_1}{x_2^2} \right) = -1$$

Anche in questo caso non ci sono problemi di amplificazione.

Esempio 5 (Esponenziale). $f(x) = e^x$

$\varepsilon_{in} = \varepsilon_x c_x$, dove

$$c_x = \frac{x}{e^x} e^x = x$$

si amplifica come x .

Esempio 6 (Logaritmo). $f(x) = \log x$

$\varepsilon_{in} = \varepsilon_x c_x$, dove

$$c_x = \frac{x}{\log x} \frac{1}{x} = \frac{1}{\log x}$$

si ha grande amplificazione per $x \cong 1$.

Esempio 7 (Elevamento a potenza). $f(x) = x^n$

$\varepsilon_{in} = \varepsilon_x c_x$, dove

$$c_x = \frac{x}{x^n} n x^{n-1} = n.$$

Esempio 8. Determinare l'errore inerente e algoritmico delle seguenti due funzioni:


$$f_1(x) = x_1^2 - x_2^2;$$

$$f_2(x) = (x_1 - x_2)(x_1 + x_2).$$

Consideriamo

$$f_1(x) = x_1^2 - x_2^2.$$

Abbiamo



$$\varepsilon_{tot1} = \varepsilon_1 \cdot 2 \cdot \frac{x_1^2}{x_1^2 - x_2^2} + \varepsilon_1 \cdot 2 \cdot \frac{-x_2^2}{x_1^2 - x_2^2} + \varepsilon^{(1)} \frac{x_1^2}{x_1^2 - x_2^2} + \varepsilon^{(2)} \frac{-x_2^2}{x_1^2 - x_2^2} + \varepsilon^{(3)}$$

$$\varepsilon_{in1} = \varepsilon_1 \cdot 2 \cdot \frac{x_1^2}{x_1^2 - x_2^2} + \varepsilon_1 \cdot 2 \cdot \frac{-x_2^2}{x_1^2 - x_2^2}$$

$$\varepsilon_{alg1} = \varepsilon^{(1)} \frac{x_1^2}{x_1^2 - x_2^2} + \varepsilon^{(2)} \frac{-x_2^2}{x_1^2 - x_2^2} + \varepsilon^{(3)}$$

$$|\varepsilon_{alg1}| = \left| \varepsilon^{(1)} \frac{x_1^2}{x_1^2 - x_2^2} + \varepsilon^{(2)} \frac{-x_2^2}{x_1^2 - x_2^2} + \varepsilon^{(3)} \right| \leq$$


$$\leq \left| \varepsilon^{(1)} \frac{x_1^2}{x_1^2 - x_2^2} \right| + \left| \varepsilon^{(2)} \frac{x_2^2}{x_1^2 - x_2^2} \right| + \left| \varepsilon^{(3)} \right| < u \left(\frac{x_1^2 + x_2^2}{|x_1^2 - x_2^2|} + 1 \right)$$

Se $x_1 \cong \pm x_2$ l'errore algoritmico potrebbe essere grande.

Consideriamo ora

$$f_2(x) = (x_1 - x_2)(x_1 + x_2).$$

Abbiamo



$$\varepsilon_{tot2} = \varepsilon_1 \cdot \frac{x_1}{x_1 - x_2} \cdot 1 + \varepsilon_1 \cdot \frac{x_1}{x_1 + x_2} \cdot 1 + \varepsilon_2 \cdot \frac{-x_2}{x_1 - x_2} \cdot 1 + \varepsilon_2 \cdot \frac{x_2}{x_1 + x_2} \cdot 1 + \varepsilon^{(1)} \cdot 1 + \varepsilon^{(2)} \cdot 1 + \varepsilon^{(3)}$$

$$\varepsilon_{in2} = \varepsilon_1 \left(\frac{x_1}{x_1 - x_2} + \frac{x_1}{x_1 + x_2} \right) + \varepsilon_2 \left(\frac{-x_2}{x_1 - x_2} + \frac{x_2}{x_1 + x_2} \right) = \varepsilon_{in1}$$

$$\varepsilon_{alg2} = \varepsilon^{(1)} + \varepsilon^{(2)} + \varepsilon^{(3)}$$

$$|\varepsilon_{alg2}| = \left| \varepsilon^{(1)} + \varepsilon^{(2)} + \varepsilon^{(3)} \right| \leq \left| \varepsilon^{(1)} \right| + \left| \varepsilon^{(2)} \right| + \left| \varepsilon^{(3)} \right| < 3u$$

L'errore algoritmico è sempre limitato.

Esempio 9. Sia $f(x) = e^{(x - \frac{1}{x})}$ con $x \neq 0$. Si dica quali dei seguenti metodi sono applicabili per il calcolo di tale funzione; si studi l'errore inerente e l'errore algoritmico dei metodi applicabili. (Assumere che l'esponenziale sia una funzione di libreria di macchina)

$$f_1(x) = e^{(x - \frac{1}{x})},$$


$$f_2(x) = e^x (-e^x),$$

$$f_3(x) = \frac{e^x}{e^{\frac{1}{x}}}.$$

Consideriamo

$$f_1(x) = e^{x - \frac{1}{x}}.$$

Abbiamo



$$\varepsilon_{tot1} = \varepsilon_x \cdot (-1) \cdot \left(\frac{-\frac{1}{x}}{x - \frac{1}{x}} \right) \left(x - \frac{1}{x} \right) + \varepsilon_x \cdot \left(\frac{x}{x - \frac{1}{x}} \right) \left(x - \frac{1}{x} \right) +$$

$$+ \varepsilon^{(1)} \left(\frac{-\frac{1}{x}}{x - \frac{1}{x}} \right) \left(x - \frac{1}{x} \right) + \varepsilon^{(2)} \left(x - \frac{1}{x} \right) + \varepsilon^{(3)}$$

Quindi

$$\varepsilon_{in1} = \varepsilon_x \left[x + \frac{1}{x} \right]$$

$$\varepsilon_{alg1} = \varepsilon^{(1)} \left(-\frac{1}{x} \right) + \varepsilon^{(2)} \left(x - \frac{1}{x} \right) + \varepsilon^{(3)}$$

$$|\varepsilon_{alg1}| = \left| \varepsilon^{(1)} \left(-\frac{1}{x} \right) + \varepsilon^{(2)} \left(x - \frac{1}{x} \right) + \varepsilon^{(3)} \right| \leq \left| \varepsilon^{(1)} \left(-\frac{1}{x} \right) \right| +$$

$$\left| \varepsilon^{(2)} \left(x - \frac{1}{x} \right) \right| + \left| \varepsilon^{(3)} \right| < u \left(\frac{1}{|x|} + \left| \frac{x^2 - 1}{x} \right| + 1 \right)$$

Tale errore potrebbe essere grande per $x \cong 0$ e $x \cong \pm\infty$.

Consideriamo

$$f_2(x) = e^x(-e^x).$$


$f_2 \neq f_1$ infatti

$$f_1(1) = e^{1-\frac{1}{1}} = 1, \quad f_2(1) = e^1(-e^1) = -e^2 \neq 1.$$

Consideriamo

$$f_3(x) = \frac{e^x}{-e^{\frac{1}{x}}}.$$

$f_1 = f_3$, inoltre



$$\varepsilon_{tot3} = \varepsilon_x \cdot x \cdot 1 + \varepsilon_x(-1)\frac{1}{x}(-1) + \varepsilon^{(1)}\frac{1}{x}(-1) + \varepsilon^{(2)}1 + \varepsilon^{(3)}(-1) + \varepsilon^{(4)}$$

$$\varepsilon_{in3} = \varepsilon_x \left[x + \frac{1}{x} \right] = \varepsilon_{in1}$$

$$\varepsilon_{alg3} = \varepsilon^{(1)} \left(-\frac{1}{x} \right) + \varepsilon^{(2)}1 - \varepsilon^{(3)}(-1) + \varepsilon^{(4)}$$

$$\begin{aligned} |\varepsilon_{alg3}| &= \left| \varepsilon^{(1)} \left(-\frac{1}{x} \right) + \varepsilon^{(2)}1 - \varepsilon^{(3)}(-1) + \varepsilon^{(4)} \right| \leq \\ &\leq \left| \varepsilon^{(1)} \left(-\frac{1}{x} \right) \right| + \left| \varepsilon^{(2)}1 \right| + \left| \varepsilon^{(3)}(-1) \right| + \left| \varepsilon^{(4)} \right| < u \left(\frac{1}{|x|} + 1 + 1 + 1 \right) \end{aligned}$$

Tale errore potrebbe essere grande per $x \cong 0$.

Capitolo 2

Metodi per la risoluzione di sistemi lineari

Sia $A \in \mathbb{R}^{n \times n}$ una matrice invertibile e $\mathbf{b} \in \mathbb{R}^n$. Il problema consiste nel determinare $\mathbf{x} \in \mathbb{R}^n$ tale che

$$A\mathbf{x} = \mathbf{b}$$

ovvero $\mathbf{x} \in \mathbb{R}^n$ tale che

$$\mathbf{x} = A^{-1}\mathbf{b}.$$

I metodi per la risoluzione numerica di sistemi lineari si dividono in:

- **diretti**: la soluzione viene calcolata in un numero finito di passi;
- **iterativi**: la soluzione viene determinata mediante il limite di una successione.

Sia $\mathbf{b} \neq 0$, ciò implica $\mathbf{x} \neq 0$, in quanto la matrice A è invertibile.

Si indichi con $\delta\mathbf{b} \in \mathbb{R}^n$ il vettore delle perturbazioni dei termini noti e con $\mathbf{x} + \delta\mathbf{x} \in \mathbb{R}^n$ la soluzione perturbata. Allora

$$A(\mathbf{x} + \delta\mathbf{x}) = \mathbf{b} + \delta\mathbf{b} \quad \Rightarrow \quad A\mathbf{x} + A\delta\mathbf{x} = \mathbf{b} + \delta\mathbf{b}$$

$$\text{da } A\mathbf{x} = \mathbf{b} \text{ risulta } A\delta\mathbf{x} = \delta\mathbf{b} \quad \Rightarrow \quad \delta\mathbf{x} = A^{-1}\delta\mathbf{b}$$

Sia $\|\cdot\|$ una norma matriciale indotta dalla norma vettoriale $\|\cdot\|$, allora $\|\delta\mathbf{x}\| = \|A^{-1}\delta\mathbf{b}\|$.

Per le norme matriciali indotte vale in generale

$$\|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\| \quad \|\delta\mathbf{x}\| \leq \|A^{-1}\| \|\delta\mathbf{b}\|.$$

Inoltre da

$$A\mathbf{x} = \mathbf{b} \quad \Rightarrow \quad \|\mathbf{b}\| = \|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\| \quad \Leftrightarrow \quad \frac{1}{\|\mathbf{x}\|} \leq \frac{\|A\|}{\|\mathbf{b}\|}$$

si ottiene che

$$\|\delta \mathbf{x}\| \leq \|A^{-1}\| \|\delta \mathbf{b}\| \Rightarrow \frac{\|\delta \mathbf{x}\|}{\|\mathbf{x}\|} \leq \|A\| \|A^{-1}\| \frac{\|\delta \mathbf{b}\|}{\|\mathbf{b}\|}$$

Definendo le seguenti quantità

$$\varepsilon_{\mathbf{x}} = \frac{\|\delta \mathbf{x}\|}{\|\mathbf{x}\|} \quad \text{errore relativo sul risultato,}$$

$$\varepsilon_{\mathbf{b}} = \frac{\|\delta \mathbf{b}\|}{\|\mathbf{b}\|} \quad \text{errore relativo sul dato,}$$

$$\mu(A) = \|A\| \|A^{-1}\| \quad \text{numero di condizionamento,}$$

si ha, in forma compatta,

$$\varepsilon_{\mathbf{x}} \leq \mu(A) \varepsilon_{\mathbf{b}}.$$

Osservando che

$$\mu(A) = \|A\| \|A^{-1}\| \geq \|AA^{-1}\| = \|I\| = 1$$

si ha $\mu(A) \geq 1$, quindi il numero di condizionamento migliore è 1.

Più in generale si può introdurre una perturbazione anche sulla matrice A , una matrice $\delta A \in \mathbb{R}^{n \times n}$ detta matrice di perturbazione di A , per cui il problema associato diventa

$$(A + \delta A)(\mathbf{x} + \delta \mathbf{x}) = (\mathbf{b} + \delta \mathbf{b}).$$

Posto $\varepsilon_A = \frac{\|\delta A\|}{\|A\|}$ si ha

$$\varepsilon_{\mathbf{x}} = \mu(A) \frac{\varepsilon_A + \varepsilon_{\mathbf{b}}}{1 - \mu(A) \varepsilon_A},$$

il che mette in risalto l'importanza del fatto che $\mu(A)$ sia il più piccolo possibile.

Definizione 1. Un problema si dice *ben posto* se la sua soluzione

- i) esiste;
- ii) è unica;
- iii) è stabile rispetto alle perturbazioni sui dati.

Se $\mu(A)$ assume valori piccoli, allora piccole perturbazioni sui dati inducono piccole perturbazioni sulla soluzione e quindi il problema risulta ben posto. In questo caso si dice che la matrice del sistema è *ben condizionata*.

Se invece $\mu(A)$ assume valori grandi, allora piccole perturbazioni sui dati possono indurre grandi perturbazioni sulla soluzione e quindi il problema può essere mal posto. In questo caso si dice che la matrice del sistema è *mal condizionata*.

Esempio 10. Data la matrice

$$A = \begin{pmatrix} 3 & 6 \\ 9 & \alpha \end{pmatrix}.$$

con $\alpha \in \mathbb{R}$. Si determini il numero di condizionamento $\mu_\infty(A)$ al variare di α .

$$\|A\|_\infty = \max\{9, 9 + |\alpha|\} = 9 + |\alpha|.$$

Determiniamo $A^{-1} = X$.

$$\begin{pmatrix} 3 & 6 \\ 9 & \alpha \end{pmatrix} \begin{pmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Dobbiamo risolvere

$$\begin{pmatrix} 3 & 6 \\ 9 & \alpha \end{pmatrix} \begin{pmatrix} x_{11} \\ x_{21} \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad \text{e} \quad \begin{pmatrix} 3 & 6 \\ 9 & \alpha \end{pmatrix} \begin{pmatrix} x_{12} \\ x_{22} \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Così

$$\begin{cases} 3x_{11} + 6x_{21} = 1 \\ 9x_{11} + \alpha x_{21} = 0 \end{cases} \quad \text{e} \quad \begin{cases} 3x_{12} + 6x_{22} = 0 \\ 9x_{12} + \alpha x_{22} = 1 \end{cases}$$

$$x_{11} = \frac{-\alpha}{54-3\alpha}, \quad x_{12} = \frac{-2}{\alpha-18}, \\ x_{21} = \frac{3}{18-\alpha}, \quad x_{22} = \frac{1}{\alpha-18}.$$

$$\begin{pmatrix} \frac{-\alpha}{54-3\alpha} & \frac{-2}{\alpha-18} \\ \frac{3}{18-\alpha} & \frac{1}{\alpha-18} \end{pmatrix} \begin{pmatrix} 3 & 6 \\ 9 & \alpha \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

$$\|A^{-1}\|_\infty = \max \left\{ \frac{|\alpha|}{3|\alpha-18|} + \frac{2}{|\alpha-18|}, \frac{3}{|\alpha-18|} + \frac{1}{|\alpha-18|} \right\} = \\ = \frac{1}{|\alpha-18|} \max \left\{ \frac{|\alpha|}{3} + 2, 4 \right\}.$$

Quindi

$$\mu_\infty(A) = \|A\|_\infty \|A^{-1}\|_\infty = \begin{cases} \frac{(9+|\alpha|)4}{|\alpha-18|} & \text{se } |\alpha| < 6, \\ \frac{(9+|\alpha|)\left(\frac{|\alpha|+2}{3}\right)}{|\alpha-18|} & \text{altrimenti.} \end{cases}$$

Dato $A\mathbf{x} = \mathbf{b}$, se $\mu(A)$ è alto si cerca una matrice P tale che:

- i) sia facilmente invertibile;
- ii) $\mu(P^{-1}A) \approx 1$.

Allora il sistema lineare da risolvere viene cambiato con

$$B\mathbf{x} = \mathbf{c}, \quad \text{dove} \quad B = P^{-1}A \text{ e } \mathbf{c} = P^{-1}\mathbf{b}.$$

Tale matrice è detta *matrice di preconditionamento del sistema lineare*.

Trovata la matrice P , si ha così che B è ben condizionata, quindi il problema risulta ben posto.

L'efficienza del metodo dipende, oltre che dalla sua stabilità numerica, anche dal suo costo computazionale, cioè dal numero di operazioni aritmetiche richieste per ottenere la soluzione. Tale costo viene in genere calcolato indicizzato sulla dimensione del sistema, n .

Si consideri il metodo di Cramer per la risoluzione di un sistema lineare del tipo $A\mathbf{x} = \mathbf{b}$. La sua soluzione può essere ottenuta tramite la regola

$$x_j = \frac{\Delta_j}{\det(A)}, \quad j = 1, \dots, n,$$

dove Δ_j è il determinante della matrice ottenuta sostituendo alla j -esima colonna di A il termine noto $\mathbf{b}$.

Se si suppone di calcolare i determinanti con la regola di Laplace, tale metodo ha un costo computazionale di $O((n+1)!)$.

Avendo a disposizione un calcolatore in grado di effettuare 10^{10} operazioni al secondo, per risolvere un sistema con 50 equazioni tramite il metodo di Cramer si impiegherebbero 9.6×10^{35} miliardi di anni.

Ciò rende il metodo di Cramer di scarso interesse numerico.

Capitolo 3

Metodi diretti

Sia $A\mathbf{x} = \mathbf{b}$.

Si decomponga A come $A = BC$, con B e C facilmente invertibili (tali matrici potrebbero essere unitarie o triangolari).

Risulta

$$BC\mathbf{x} = \mathbf{b}$$

da cui, posto $\mathbf{y} = C\mathbf{x}$, si ha

$$B\mathbf{y} = \mathbf{b} \quad \Rightarrow \quad \mathbf{y} = B^{-1}\mathbf{b},$$

$$C\mathbf{x} = \mathbf{y} \quad \Rightarrow \quad \mathbf{x} = C^{-1}\mathbf{y}.$$

Fattorizzazione LU: Si pone $A = LU$, con

- L (lower triangular): matrice triangolare inferiore con elementi principali uguali a 1;
- U (upper triangular): matrice triangolare superiore.

Il termine di ordine maggiore nel costo computazionale è $\frac{2}{3}n^2$.

Fattorizzazione di Cholesky: Si pone $A = LL^T$, dove

L : matrice triangolare inferiore con elementi principali positivi.

Tale fattorizzazione si può fare solo se A è simmetrica e definita positiva.

Il termine di ordine maggiore nel costo computazionale è $\frac{1}{3}n^2$.

Fattorizzazione QR: Si pone $A = QR$, dove

- Q : matrice unitaria;
- R : matrice triangolare superiore.

Il termine di ordine maggiore nel costo computazionale è $\frac{4}{3}n^2$, ma è più stabile rispetto alla fattorizzazione LU .

Sia $A\mathbf{x} = \mathbf{b}$, con $A \in \mathbb{R}^{n \times n}$ matrice triangolare superiore, allora

$$\sum_{j=1}^n a_{ij}x_j = b_i \quad \text{per } i = 1, \dots, n,$$

che può anche essere riscritto come

$$\begin{cases} a_{ii}x_i + \sum_{j=i+1}^n a_{ij}x_j = b_i, & i = 1, \dots, n-1 \\ a_{nn}x_n = b_n \end{cases}$$

Poiché A è non singolare risulta $a_{ii} \neq 0$ per $i = 1, \dots, n$, quindi il sistema diventa

$$\begin{cases} x_n = \frac{b_n}{a_{nn}} \\ x_i = \frac{1}{a_{ii}} \left[b_i - \sum_{j=i+1}^n a_{ij}x_j \right], & i = n-1, \dots, 1 \end{cases}$$

Si procede calcolando in ordine $x_n, x_{n-1}, \dots, x_1$. All' i -esimo passo per calcolare x_i vengono utilizzate le componenti di indice maggiore di i , già calcolate.

Tale metodo viene chiamato *metodo di sostituzione all'indietro*.

Per il costo computazionale, basta notare che ad ogni iterazione vengono fatte $(n - i + 1)$ moltiplicazioni e divisioni, quindi in totale

$$\sum_{i=1}^n (n - i + 1) = \sum_{i=1}^n i = \frac{n(n+1)}{2}.$$

Il termine di ordine superiore è $\frac{n^2}{2}$.

Un calcolo simile si ha per le addizioni e sottrazioni, quindi il termine di ordine superiore diventa n^2 .

Capitolo 4

Metodi iterativi

Sia $A\mathbf{x} = \mathbf{b}$ e si consideri la seguente *decomposizione additiva*

$$A = M - N,$$

dove M è non singolare e facilmente invertibile. Risulta

$$(M - N)\mathbf{x} = \mathbf{b} \quad \Leftrightarrow \quad M\mathbf{x} - N\mathbf{x} = \mathbf{b} \quad \Leftrightarrow \quad M\mathbf{x} = N\mathbf{x} + \mathbf{b} \quad \Leftrightarrow$$

$$\mathbf{x} = M^{-1}(N\mathbf{x} + \mathbf{b}) \quad \Leftrightarrow \quad \mathbf{x} = M^{-1}N\mathbf{x} + M^{-1}\mathbf{b}.$$

Posti $P = M^{-1}N$ matrice di iterazione e $\mathbf{q} = M^{-1}\mathbf{b}$, si ha

$$A\mathbf{x} = \mathbf{b} \quad \Leftrightarrow \quad \mathbf{x} = P\mathbf{x} + \mathbf{q},$$

cioè $\mathbf{x}$ è soluzione del sistema se e soltanto se $\mathbf{x}$ è *punto fisso* della funzione $g(\mathbf{x}) = P\mathbf{x} + \mathbf{q}$, con $g : \mathbb{R}^n \rightarrow \mathbb{R}^n$.

$\bar{\mathbf{x}} \in \mathbb{R}^n$ è punto fisso di g se $g(\bar{\mathbf{x}}) = \bar{\mathbf{x}}$.

Il **metodo iterativo** è il seguente: dato $\mathbf{x}_0$, la successione di approssimazione alla soluzione è

$$\mathbf{x}_i = P\mathbf{x}_{i-1} + \mathbf{q}.$$

Teorema 2. Se la successione risulta convergente a $\mathbf{x}^*$, cioè

$$\lim_{i \rightarrow \infty} \mathbf{x}_i = \mathbf{x}^*,$$

allora $\mathbf{x}^*$ è il punto fisso di g , cioè $\mathbf{x}^* = P\mathbf{x}^* + \mathbf{q}$, e quindi è soluzione del sistema, cioè $A\mathbf{x}^* = \mathbf{b}$.

Dimostrazione.

$$\mathbf{x}^* = \lim_{i \rightarrow \infty} \mathbf{x}_i = \lim_{i \rightarrow \infty} \mathbf{x}_{i+1} = \lim_{i \rightarrow \infty} (P\mathbf{x}_i + \mathbf{q}) = P \lim_{i \rightarrow \infty} \mathbf{x}_i + \mathbf{q} = P\mathbf{x}^* + \mathbf{q}.$$

□

Definizione 2. Un metodo iterativo si dice *convergente* se il metodo converge alla soluzione per ogni $\mathbf{x}_0$ punto iniziale.

Sia $\mathbf{x}^*$ la soluzione del sistema, cioè $\mathbf{x}^* = A^{-1}\mathbf{b}$.

Un metodo iterativo $\mathbf{x}_i = P\mathbf{x}_{i-1} + \mathbf{q}$ è convergente se e solo se

$$\forall \mathbf{x}_0 \in \mathbb{R}^n \quad \lim_{i \rightarrow \infty} \mathbf{x}_i = \mathbf{x}^*.$$

Sia

$$\mathbf{e}_i = \mathbf{x}_i - \mathbf{x}^* \quad \text{errore al passo } i\text{-esimo}$$

$$\mathbf{e}_0 = \mathbf{x}_0 - \mathbf{x}^* \quad \text{errore iniziale}$$

$$\mathbf{e}_i = P\mathbf{x}_{i-1} + \mathbf{q} - P\mathbf{x}^* - \mathbf{q} = P(\mathbf{x}_{i-1} - \mathbf{x}^*) = P\mathbf{e}_{i-1} = P(P\mathbf{e}_{i-2}) = \dots = P^i\mathbf{e}_0$$

Allora la convergenza di un metodo si può caratterizzare come

$$\forall \mathbf{x}_0 \in \mathbb{R}^n \quad \lim_{i \rightarrow \infty} \mathbf{x}_i = \mathbf{x}^* \quad \Leftrightarrow \quad \forall \mathbf{e}_0 \in \mathbb{R}^n \quad \lim_{i \rightarrow \infty} \mathbf{e}_i = \lim_{i \rightarrow \infty} P^i\mathbf{e}_0 = \mathbf{0}$$

Teorema 3. Sia $A \in \mathbb{R}^{n \times n}$, allora

$$\lim_{i \rightarrow \infty} A^i = O \quad \Leftrightarrow \quad \rho(A) < 1.$$

Dimostrazione. ($\Leftarrow$) Si assuma A diagonalizzabile, allora $A = PDP^{-1}$, con

$$D = \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix} \quad P = \left(x_1 \mid \cdots \mid x_n \right)$$

$A^2 = PDP^{-1}PDP^{-1} = PD^2P^{-1}$ è la diagonalizzazione di A^2 , dove

$$D^2 = \begin{pmatrix} \lambda_1^2 & & 0 \\ & \ddots & \\ 0 & & \lambda_n^2 \end{pmatrix}$$

Ora supposta vera $A^{i-1} = PD^{i-1}P^{-1}$ per induzione si prova che

$$A^i = A^{i-1}A = PD^{i-1}P^{-1}PDP^{-1} = PD^iP^{-1},$$

dove

$$D^i = \begin{pmatrix} \lambda_1^i & & 0 \\ & \ddots & \\ 0 & & \lambda_n^i \end{pmatrix}.$$

Allora

$$\lim_{i \rightarrow \infty} A^i = \lim_{i \rightarrow \infty} PD^iP^{-1} = P \left(\lim_{i \rightarrow \infty} D^i \right) P^{-1} = P \lim_{i \rightarrow \infty} \begin{pmatrix} \lambda_1^i & & 0 \\ & \ddots & \\ 0 & & \lambda_n^i \end{pmatrix} P^{-1}$$

$$= P \begin{pmatrix} \lim_{i \rightarrow \infty} \lambda_1^i & & 0 \\ & \ddots & \\ 0 & & \lim_{i \rightarrow \infty} \lambda_n^i \end{pmatrix} P^{-1} = POP^{-1} = O.$$

($\Rightarrow$)

$$\lim_{i \rightarrow \infty} A^i = \lim_{i \rightarrow \infty} PD^i P^{-1} = O$$

$$\lim_{i \rightarrow \infty} D^i = \begin{pmatrix} \lim_{i \rightarrow \infty} \lambda_1^i & & 0 \\ & \ddots & \\ 0 & & \lim_{i \rightarrow \infty} \lambda_n^i \end{pmatrix} = Q$$

Q è una matrice diagonale con $q_{ii} = \lim_{j \rightarrow \infty} \lambda_i^j$.

$PQP^{-1} = O$, quindi Q è simile alla matrice $O \Rightarrow \lambda_i^Q = 0 \quad \forall i = 1, \dots, n$.

Allora

$$\lim_{j \rightarrow \infty} \lambda_i^j = 0 \quad \forall i = 1, \dots, n \quad \Leftrightarrow \quad |\lambda_i| < 1 \quad \forall i = 1, \dots, n \quad \Leftrightarrow \quad \rho(A) < 1.$$

□

Teorema 4. *Un metodo iterativo è convergente se e solo se $\rho(P) < 1$.*

Dimostrazione. Si proverà quindi che

$$\forall \mathbf{e}_0 \in \mathbb{R}^n \quad \lim_{i \rightarrow \infty} P^i \mathbf{e}_0 = \mathbf{0} \quad \Leftrightarrow \quad \rho(P) < 1.$$

($\Leftarrow$) Sia $\rho(P) < 1$, allora

$$\forall \mathbf{e}_0 \in \mathbb{R}^n \quad \lim_{i \rightarrow \infty} P^i \mathbf{e}_0 = \left(\lim_{i \rightarrow \infty} P^i \right) \mathbf{e}_0 = O \mathbf{e}_0 = \mathbf{0}$$

($\Rightarrow$) Per assurdo, sia $\rho(P) \geq 1$, $P\mathbf{y} = \lambda\mathbf{y}$ con $|\lambda| \geq 1$.

Posto $\mathbf{e}_0 = \mathbf{y} \Rightarrow P\mathbf{e}_0 = \lambda\mathbf{e}_0 \Rightarrow P^i \mathbf{e}_0 = \lambda^i \mathbf{e}_0$, da cui si ha

$$\lim_{i \rightarrow \infty} P^i \mathbf{e}_0 = \lim_{i \rightarrow \infty} \lambda^i \mathbf{e}_0 = \left(\lim_{i \rightarrow \infty} \lambda^i \right) \mathbf{e}_0 \neq \mathbf{0},$$

poichè $\mathbf{e}_0$ è un autovettore e $|\lambda| \geq 1$.

□

Teorema 5. *Sia $\|\cdot\|$ una norma matriciale indotta. Se $\|P\| < 1$ allora il metodo iterativo è convergente.*

Dimostrazione. Per una proprietà delle norme matriciali indotte vale $\|P\| \geq \rho(P)$, allora

$$\rho(P) \leq \|P\| < 1 \quad \Rightarrow \quad \text{il metodo converge.}$$

□

Teorema 6. Condizione necessaria alla convergenza di un metodo iterativo è

$$|\text{tr}(P)| < n \quad e \quad |\det(P)| < 1.$$

Dimostrazione.

Se un metodo iterativo è convergente abbiamo che $\rho(P) < 1$, quindi $|\lambda| < 1$, $\forall \lambda \in \Lambda(P)$. Così la loro somma sarebbe compresa strettamente tra $-n$ e n , quindi

$$|\text{tr}(P)| < n.$$

Inoltre la loro moltiplicazione sarebbe compresa strettamente tra -1 e 1 , quindi

$$|\det(P)| < 1.$$

□

Per il *metodo di Gauss-Seidel* abbiamo che data

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix}$$

per la decomposizione additiva si sceglie M triangolare inferiore nel seguente modo

$$M = \begin{pmatrix} a_{11} & 0 & \dots & 0 \\ a_{21} & a_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix} \Rightarrow N = \begin{pmatrix} 0 & -a_{12} & \dots & -a_{1n} \\ 0 & 0 & \dots & -a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{pmatrix}.$$

Per il *metodo di Jacobi* abbiamo che data

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix}$$

per la decomposizione additiva si sceglie M diagonale nel seguente modo

$$M = \begin{pmatrix} a_{11} & 0 & \dots & 0 \\ 0 & a_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & a_{nn} \end{pmatrix} \Rightarrow N = \begin{pmatrix} 0 & -a_{12} & \dots & -a_{1n} \\ -a_{21} & 0 & \dots & -a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{n1} & -a_{n2} & \dots & 0 \end{pmatrix}.$$

Esempio 11. Data la seguente matrice

$$A = \begin{pmatrix} 0 & 1 \\ k & k \end{pmatrix}$$

con $k \neq 0$, e la decomposizione additiva

$$A = M - N$$

con

$$M = \begin{pmatrix} 0 & 1 \\ k & 1 \end{pmatrix},$$

si determini per quali valori del parametro k il metodo iterativo associato risulta convergente.

Abbiamo che

$$A = M - N \quad \text{e quindi} \quad N = M - A.$$

In questo caso abbiamo

$$N = \begin{pmatrix} 0 & 1 \\ k & 1 \end{pmatrix} - \begin{pmatrix} 0 & 1 \\ k & k \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 1 - k \end{pmatrix}.$$

Invertiamo ora la matrice M , cioè determiniamo $X \in \mathbb{R}^{n \times n}$ tale che

$$MX = I$$

In questo caso

$$X = (\mathbf{x}_1 \quad \mathbf{x}_2) \quad \text{con} \quad \mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^2.$$

$$I = (\mathbf{e}_1 \quad \mathbf{e}_2) \quad \mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

$$M(\mathbf{x}_1 \quad \mathbf{x}_2) = (\mathbf{e}_1 \quad \mathbf{e}_2) \quad \Leftrightarrow \quad (M\mathbf{x}_1 \quad M\mathbf{x}_2) = (\mathbf{e}_1 \quad \mathbf{e}_2)$$

$$\begin{cases} M\mathbf{x}_1 = \mathbf{e}_1 \\ M\mathbf{x}_2 = \mathbf{e}_2 \end{cases}$$

$$M\mathbf{x}_1 = \begin{pmatrix} 0 & 1 \\ k & 1 \end{pmatrix} \begin{pmatrix} x_{11} \\ x_{21} \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$\begin{cases} x_{21} = 1 \\ kx_{11} + x_{21} = 0 \end{cases} \quad \begin{cases} x_{21} = 1 \\ kx_{11} = -1 \end{cases} \quad \begin{cases} x_{21} = 1 \\ x_{11} = -\frac{1}{k} \end{cases}$$

$$M\mathbf{x}_2 = \begin{pmatrix} 0 & 1 \\ k & 1 \end{pmatrix} \begin{pmatrix} x_{12} \\ x_{22} \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

$$\begin{cases} x_{22} = 0 \\ kx_{12} + x_{22} = 1 \end{cases} \quad \begin{cases} x_{22} = 0 \\ x_{12} = \frac{1}{k} \end{cases}$$

$$X = M^{-1} = \begin{pmatrix} -\frac{1}{k} & \frac{1}{k} \\ 1 & 0 \end{pmatrix}$$

Infatti

$$M^{-1}M = \begin{pmatrix} -\frac{1}{k} & \frac{1}{k} \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ k & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$P = M^{-1}N = \begin{pmatrix} -\frac{1}{k} & \frac{1}{k} \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 0 & 1-k \end{pmatrix} = \begin{pmatrix} 0 & \frac{1-k}{k} \\ 0 & 0 \end{pmatrix}$$

P è triangolare superiore $\Rightarrow \lambda_1^P = \lambda_2^P = 0 \Rightarrow \rho(P) = 0$.

Così il metodo è convergente $\forall k \neq 0$.

Esempio 12. Data la seguente matrice

$$A = \begin{pmatrix} 1 & 1 & 1 & 1 & 1+\alpha \\ 1 & 1 & 1 & 1+\alpha & 1 \\ 1 & 1 & 1+\alpha & 1 & 1 \\ 1 & 1+\alpha & 1 & 1 & 1 \\ 1+\alpha & 1 & 1 & 1 & 1 \end{pmatrix}$$

con $\alpha \neq 0$, e la decomposizione additiva

$$A = M - N$$

con

$$M = \begin{pmatrix} 0 & 0 & 0 & 0 & \alpha \\ 0 & 0 & 0 & \alpha & 0 \\ 0 & 0 & \alpha & 0 & 0 \\ 0 & \alpha & 0 & 0 & 0 \\ \alpha & 0 & 0 & 0 & 0 \end{pmatrix}.$$

Si determini per quali valori del parametro α il metodo iterativo associato risulta convergente.

In questo caso abbiamo:

$$N = M - A = - \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{pmatrix}.$$

Invertiamo ora la matrice M :

$$M = \alpha \begin{pmatrix} 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \end{pmatrix} = \alpha J.$$

J è una matrice di permutazione, quindi è ortogonale, cioè

$$JJ^T = I.$$

Quindi $J^{-1} = J^T = J$.

Così

$$M^{-1} = (\alpha J)^{-1} = \frac{1}{\alpha} J^{-1} = \frac{1}{\alpha} J = \begin{pmatrix} 0 & 0 & 0 & 0 & \frac{1}{\alpha} \\ 0 & 0 & 0 & \frac{1}{\alpha} & 0 \\ 0 & 0 & \frac{1}{\alpha} & 0 & 0 \\ 0 & \frac{1}{\alpha} & 0 & 0 & 0 \\ \frac{1}{\alpha} & 0 & 0 & 0 & 0 \end{pmatrix}$$

$$P = M^{-1}N = \frac{1}{\alpha} \begin{pmatrix} 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 \end{pmatrix} =$$

$$= -\frac{1}{\alpha} \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{pmatrix} = -\frac{1}{\alpha} B$$

con

$$B = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{pmatrix}.$$

Calcoliamo gli autovalori di B .

$$\text{rg}(B) = 1 \implies \det(B) = 0$$

$$\det(B) = \prod_{i=1}^5 \lambda_i^B = 0 \implies \exists \lambda_i = 0$$

Una proprietà degli autovalori ci dice che se il rango di una matrice è k , allora esistono almeno $n - k$ autovalori nulli.

Quindi

$$\lambda_1^B = \lambda_2^B = \lambda_3^B = \lambda_4^B = 0.$$

Inoltre sappiamo che

$$\text{tr}(B) = \sum_{i=1}^5 b_{ii} = 5 = \sum_{i=1}^5 \lambda_i^B = \lambda_5^B.$$

Notare che la somma degli elementi in ogni riga della matrice B è costante ed è sempre 5.

In questo caso la costante è un autovalore e l'autovettore associato è

$$\mathbf{x} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}.$$

Infatti

$$B\mathbf{x} = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 5 \\ 5 \\ 5 \\ 5 \\ 5 \end{pmatrix} = 5 \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} = 5\mathbf{x}.$$

Gli autovalori di $P = -\frac{1}{\alpha}B$ sono dunque

$$\lambda_1^B = \lambda_2^B = \lambda_3^B = \lambda_4^B = 0 \quad \lambda_5^B = -\frac{5}{\alpha}.$$

Quindi

$$\rho(P) < 1 \iff \left| \frac{5}{\alpha} \right| < 1 \iff |\alpha| > 5.$$